

תכנית עבודה: Scouting System לחיזוי שווי

המערכת תיבנה כמודל ייחודי עבור כל אחד מ-4 הדאטאסטים של אזורי המגרש (שוערים, הגנה, קישור, התקפה), כאשר כל חבר צוות אחראי על אזור מגרש אחד (והתהליך המלא עבורו – בחירת קטגוריות, הנדסת פיצ'רים, בחינת מודלים שונים, אימון, בדיקה, מסקנות). דגשים:

- **המבנה הקיים** הוא שורה עבור כל שחקן ייחודי בעונה ייחודית. כלומר (שחקן, עונה). יש שחקנים שמופיעים בכל העונות, חלקן וכו'.
- סה"כ 8 עונות, לכן לצורך אימון מודל **נצטרך לחתוך את הנתונים** (למשל סוף 2021/22) לנתוני אימון-בדיקה, כדי שנוכל לאמן ואז לבחון מול שווי האמת של העתיד. שיהיה מספיק מידע על העתיד. (למשל לעונת 2024/25 אין לנו נתוני עתיד מעבר לה ולכן לא ניתן לאמן עליה, כנ"ל 2023/24 עונה אחת רק אחרי).
- ביסוס המודל והפרמטרים: **כדי לא להתאים רק לנקודת זמן מסוימת**, לקחת את סוג המודל והפרמטרים המטוייבים עבור המודל שאימנו **ולבדוק אותם על חיתוכי שנים אחרות (אימון מודלים מחדש עם דאטא שנחתכת בנק' זמן שונה)**. אם זה ייתן תוצאות טובות גם שם – המבנה מזהה היטב את המגמות וניתן לאמן את כל הדאטא על מודל חדש המבוסס על כך.
- **להסיר מזהים** (מזהה שחקן, ליגה ספציפית, קבוצה ספציפית, תאריך לידה וכו'): הטעיה ברורה של העץ. לשנות למאפיינים כללים: חוזק ליגה, חוזק קבוצה ביחס לליגה, גיל וכו'.
- **ENSEMBLE**: ליציבות ומניעת רעשים. ישדרג את יכולת החיזוי והקביעה בהרבה.

צעדי עבודה מומלצים לכל אחד בתוך החלק שלו:

1: אימון המודל הראשון – בניית נתוני האימון:

בניית וקטור המאפיינים (פיצ'רים) של כל שחקן לאימון המודל ("שחקן אחד = שורה אחת")

כדי שהמודל יבין היסטוריה, אנו אורזים עבור כל שחקן את כל המידע שלו עד "נקודת החיתוך" לתוך שורה מתמטית אחת עשירה. השורה תכלול:

1. מאפייני יסוד (Metadata):

- כל מה שקיים **(ללא מזהים – להתבסס על מאפיינים כלליים)** + מה שחושבים שחשוב
- league strength, team strength, age_at_season, position, n_prior_seasons (כמה עונות בוגרים עשה עד כה) וכו'.

2. כל מאפייני המשחק של העונה האחרונה - הליבה הסטטיסטית): משאירים את כל הסטטיסטיקות הרלוונטיות לאזור המגרש הספציפי מתוך העונה שהסתיימה הרגע.

3. אגרגציות משחק היסטוריות (תמצית העבר): מסכמים את כל העונות שקדמו לעונה האחרונה כדי ללמד את המודל על הרמה והפוטנציאל הרגילים: **לכל קטגוריה ניתן למשל ליצור:**

- historical_mean_[stat]: הממוצע הקבוע של השחקן (הרמה הרגילה).
- historical_max_[stat]: תקרת הזכוכית (למה הוא מסוגל כשהכל מתחבר).
- historical_std_[stat]: מידת העקביות שלו (יציב או תנודתי).

4. מאפייני מומנטום ודלתא (מגמה): מאפייני ההווה ביחס למאפייני העבר (למשל עמודות של הפער) כדי למצוא נסיקה או התרסקות:

- last_season_vs_mean: עונה אחרונה פחות ממוצע (מראה שיפור יציב).
- Last_season_vs_max: עונה אחרונה פחות המקסימום (סיגנל פריצה – שחקן שובר את שיאי עצמו).

5. הקשר פיננסי (Market Value):

- שווי השוק בתחילת העונה האחרונה ובסופה (קיים – לשמור), שווי השוק המקסימלי שיגיע אליו בעתיד (זה ה-Y – לשמור), ניתן להוסיף למשל מגמה של ירידה/עלייה מהעבר וכו'.

שלב 2: אימון מעשי של המודל:

כאן מאמנים את המודל ומוכיחים את היכולות שלו בצורה הכי שקופה ואמינה.

1. **חיתוך הדאטא:** מאמנים על כל ההיסטוריה עד קיץ 2021/22. המטרה: שווי שיא בין השנים 22/23 ל-24/25.
2. **פיצול:** 80% מהשחקנים לאימון, 20% למבחן (Test Set). מציאת היפר-פרמטרים אופטימליים.
3. **המלצה: הערכה מפולחת לפי גיל (Segmented):** במקום להציג ציון MAE כללי אחד, הדו"ח יציג את הדיוק לפי קבוצות:
 - **צעירים (עד גיל 21):** ה-MAE יהיה גבוה יותר באופן טבעי (שונות עצומה, פוטנציאל גבוה).
 - **שיא הקריירה (22-27):** דיוק בינוני-גבוה.
 - **ותיקים (+28):** ה-MAE יהיה הנמוך ביותר (שחקנים ששומרים על ערכם או דועכים לאט). הערכה כזו מוכיחה למרצים ולמגייסים שאתם מבינים בדיוק איפה האלגוריתם חזק ואיפה מרווח הטעות טבעי וגדול.

שלב 3: אימות תהליך ויציבות (Stability Validation)

מוכיחים שהמתכון עובד תמיד:

1. לוקחים את הפרמטרים מהמעבדה.
2. מאמנים ובוחנים על שתי נקודות זמן נוספות: חיתוך ב-2020/21, וחיתוך ב-2022/23.
3. הצגת תוצאות יציבות מוכיחה שהמודל מבין את כלכלת הכדורגל ולא שיהן שנה ספציפית.

שלב 4: מערכת הפרודקשן לסקאוט (The Production Ensemble)

המוצר הסופי. כדי לחזות את המחר (קיץ 2025), אנו משלבים את הכלים המתקדמים ביותר:

1. **Uncertainty Bagging (האנסמבל הפנימי):** עבור כל חיתוך זמן היסטורי (20/21, 21/22, 22/23), מאמנים 10 מודלים על דגימות חוזרות. זה מייצר עבור כל שחקן "טווח אי-ודאות" במקום מספר בודד.
2. **Time-Ensemble (האנסמבל החיצוני):** מזינים את הנתונים הטריים של היום (סוף עונת 24/25) פנימה. המערכת מחשבת את החציון (Median) של 3 המודלים הגדולים (של תקופות הזמן), כדי לנטרל רעשי שוק ואינפלציה מקומית.
3. **התוצר הסופי במסך של הסקאוט:** המערכת מגישה המלצה שכוללת את החיזוי החציוני (למשל €M80), יחד עם רווח סמך/סיכון (€M€-110M60) הנובע מאופי השחקן ומידת ההסכמה בין המודלים השונים. מודל סקאוטינג שלא רק מנבא הצלחה, אלא מנהל את הסיכון הפיננסי.

```
scouting-ai-project/
├── .gitignore          <-- Prevents uploading CSV/Data files
├── README.md          <-- Project goals and setup guide
├── data/              <-- LOCAL ONLY (Not on Git)
│   ├── raw/           <-- Original positional CSV (e.g., database_ATT.
│   └── processed/     <-- Output for engineered features/vectors
├── notebooks/         <-- Research, plots, and data exploration (EDA)
│   └── att_exploration.ipynb
└── src/               <-- Code pushed to Git
    ├── attack_model/  <-- Ido's isolated workspace
    │   ├── 01_preprocess.py <-- Data cleaning and type handling
    │   ├── 02_features.py  <-- Vectorization: Mean, Std, and Deltas
    │   ├── 03_train.py     <-- XGBoost training and tuning
    │   ├── 04_evaluate.py  <-- Error analysis and MAE testing
    │   └── config.py       <-- Paths and hyperparameters
```